

深層学習を用いた動的電極選択による個人最適化脳波疲労検知と仮想空間への応用

大野峻輝

1 はじめに

近年、交通機関におけるヒューマンエラーに起因する重大事故が後を絶たず、その背景にあるオペレーターの疲労や過労が深刻な社会問題として認識されている。特に、居眠り・疲労運転は交通事故の主要な原因となっており、アメリカの年間の死亡事故の約 17.6%が疲労に関連している [1]。また、欧州においては重大な交通事故の 15~20%がドライバーの疲労が起因と推定されている [2]。事故は 0.5 秒前に警告するだけで事故の最大約 60%を防止できる可能性がある [3]。事故のこのような事故を未然に防ぐためには、疲労検知をすることである。疲労検知の方法として、カメラや生体情報を利用する方法がある。カメラは外的要因によって検知に影響が生じてしまう。生体情報の中でも脳波は最もリアルタイムな情報取得が可能であり、心理的・精神的な情報も考慮可能なため、有効なアプローチとして、脳波での疲労検知が注目されている [4]。脳波の計測には、頭皮上に電極を配置するだけで計測可能である Electro Encephalo Graphy (EEG) が広く用いられる。EEG は、被験者の身体への負担がない非侵襲的な手法であり、安全性と利便性の観点から実用性に優れている。一方で、EEG から得られる脳波データは、時空間的に非常に複雑な信号であり、その解析には高度な情報処理技術が求められる [5]。この課題に対し、深層学習は複雑なデータから特徴を自動で抽出し、高い識別性能を発揮する手法として有効性が示されている。しかし、既存の深層学習を用いた研究の多くは精度向上を主目的としており、多数の電極情報を用いることでモデルが大規模化し、計算コストが増大する傾向にある [6]。これは、ウェアラブルデバイスなどでの実用化を想定した場合に大きな制約となる。また、脳波の現れ方には個人差があり、全ての被験者に対して固定的な電極配置を用いる従来のアプローチでは、個々人の状態変化を十分に捉えきれないという課題も残されている [7]。

そこで本研究では、実用面での利便性と省エネルギー化を重視し、可能な限り少ない電極数で高い推定精度を達成することを目的とする。具体的には、個人ごとに最適な電極の組み合わせを動的に選択するアルゴリズム (Dynamic Gate Mechanism) を構築し、個人に最適化された少数電極によって脳波解析の精度を安定化させる手法を提案する。本アプローチは、不要な情報を遮断

し必要な信号のみを適応的に取得することで、EEG 計測の利便性向上とデバイスの消費電力削減を同時に実現するものである。本研究は、高精度かつ軽量の疲労検知システムの構築を通じ、その社会実装に貢献することを目指す。

2 関連研究

本章では、EEG を用いた関連研究の例について紹介する。

2.1 Liu らの研究 [8]

本研究は私が主に扱うデータセットを活用している最新の研究である。

2.1.1 概要

この研究では、重大な事故を避けるために運転時のドライバーの疲労検知を目標としている。従来の課題点であった「生理学的な周波数帯域ごとのリズム」と「複雑な時空間的な依存関係」を低いコストで解析することの解決に向けた取り組みを実施している。周波数ごとに分けたカーネルと改良した Transformer を利用することでこれらの課題解決に繋げている。

2.1.2 提案手法

図 1 に提案されたアーキテクチャの全体像を提示する。このアーキテクチャは 4 つに大別される。1 つ目




図 1: MB-STFormer の全体像。

は、マルチバンド特徴抽出である。脳波を 5 つの周波数帯域に分解し、それぞれの特徴に合わせたカーネルを適用する。周波数が低いほど長く、高いほど短いカー

ネルを適用し、各周波数に特化した特徴抽出を実施することが可能になっている。さらに、電極間と時間軸の両方を同時にモデル化し、ベクトルの作成を行っている。次に、EAA(Efficient Additive Attention)である。図2に詳細を提示する。通常のTransformerと異なり、




図 2: EAA の詳細処理工程。

Value を扱わず、乗算を行わない。特徴抽出したベクトルと学習可能なパラメータにより、 Q 行列と K 行列を作成する。

$$Q = XW_q, K = XW_k \quad (1)$$

作成した Q 行列を Value の代わりに学習可能なベクトルとの掛け合わせを行い、正規化する。

$$\alpha = \frac{QW_a}{\sqrt{d}} \quad (2)$$

これにより、どの特徴に注目すれば良いか判別する attention が作成される。算出した attention を Q 行列と加重平均取ることによりグローバルクエリを作成する。

$$q = \sum_{i=1}^N \alpha_i Q_i \quad (3)$$

求めたグローバルクエリ q を K 行列とアダマール積を取ることで特徴を抽出する。これらの工程により、通常の Transformer では計算量が $O(n^2)$ になるのに対して、 $O(n)$ で済むことになる。

次に、対数パワー符号化である。EAA 実施後の特徴を対数スペクトル表現に変換し、数値的な安定性を高める。

最後に、分類器にかけることで疲労検知を行う。

そしてこれらのモデルは、2 段階のトレーニングプロセスにより学習させる。1 段階目では、データを 10 個に分け、9 個を学習用、1 個をテスト用に分割する。そして 9 個を 3 分割交差検証で学習をさせる。そして、2

段階目は全てのデータを用いて、エポックが 20 に達するか訓練精度が 100%になるタイミングで終了させる。

2.1.3 実験結果

提案されたモデル、トレーニングの結果が以下になる。表 1 では 2 値分類の各データセットに適用し、既存のモデルとの比較を行っている。実装したモデルの中では最高精度を更新していることがわかる。LOSO 法

表 1: データセットごとの結果 [8].

Dataset	Methods	Accuracy	Precision	Recall	F1-score
SADT	LGGNet [31]	89.03 ± 5.20**	88.77 ± 5.19**	87.45 ± 5.83**	87.12 ± 5.60**
	EEGNet [14]	89.09 ± 9.11**	88.92 ± 7.82**	84.58 ± 13.48**	84.49 ± 13.06**
	Deformer [23]	84.28 ± 7.63**	85.61 ± 6.82**	81.85 ± 7.68**	81.25 ± 7.28**
	LMDA [15]	89.18 ± 6.01**	88.79 ± 6.67**	85.99 ± 7.68**	86.36 ± 7.18**
	Conformer [16]	90.80 ± 6.37*	89.67 ± 9.03*	89.11 ± 9.70*	88.75 ± 9.63**
	MB-STFormer	93.89 ± 4.98	92.55 ± 5.82	91.81 ± 6.23	91.74 ± 6.38
SEED-VIG	LGGNet [31]	83.32 ± 11.79**	75.96 ± 15.06**	73.23 ± 15.57**	73.89 ± 15.08**
	EEGNet [14]	83.06 ± 11.71**	74.87 ± 17.64**	71.77 ± 18.66**	71.10 ± 18.18**
	Deformer [23]	79.40 ± 10.84**	74.16 ± 14.08**	72.59 ± 14.44**	70.67 ± 14.37**
	LMDA [15]	81.11 ± 11.71**	73.58 ± 16.81**	70.45 ± 17.51**	70.29 ± 17.06**
	Conformer [16]	83.85 ± 11.30**	73.88 ± 17.06**	71.83 ± 18.02**	71.45 ± 17.83**
	MB-STFormer	87.39 ± 8.88	83.85 ± 11.70	81.73 ± 13.70	81.05 ± 13.09
SEED-VLA	LGGNet [31]	87.26 ± 10.44	75.71 ± 16.15	74.13 ± 16.53	73.59 ± 16.98*
	EEGNet [14]	84.24 ± 11.94**	70.41 ± 18.96**	68.15 ± 17.37**	66.87 ± 18.48**
	Deformer [23]	87.45 ± 11.90	74.15 ± 15.06*	72.64 ± 17.82**	75.30 ± 16.91
	LMDA [15]	85.53 ± 10.91*	74.15 ± 17.81*	71.18 ± 17.39**	70.66 ± 18.06**
	Conformer [16]	85.86 ± 14.48*	71.82 ± 21.95**	70.77 ± 23.66**	69.60 ± 23.12**
	MB-STFormer	87.62 ± 11.83	76.70 ± 17.93	75.77 ± 19.15	75.71 ± 18.73

を活用した結果が表 2 になる。最高精度になっていることが読み取れ、精度は約 76.72 である。疲労時と覚醒

表 2: SADT における LOSO 法の結果 [8].

ID	LGGNet		EEGNet		Deformer		LMDA		Conformer		MB-STFormer	
	Acc.	F1	Acc.	F1	Acc.	F1	Acc.	F1	Acc.	F1	Acc.	F1
1	77.49	77.46	80.10	79.81	83.81	83.77	83.25	83.22	82.19	81.98	83.77	84.76
2	41.36	37.45	73.59	49.07	58.57	44.59	59.34	44.74	41.58	33.40	67.52	48.82
3	40.78	38.96	59.21	59.11	69.99	67.51	45.10	45.03	73.33	69.03	78.43	74.27
4	54.97	54.61	70.16	70.15	67.06	66.83	59.68	59.57	70.15	70.10	63.35	64.22
5	82.35	80.49	76.10	71.72	84.66	83.84	84.55	83.17	84.92	84.42	83.08	82.96
6	64.82	64.80	76.38	76.37	80.40	80.39	78.39	77.62	81.41	80.01	84.42	85.40
7	69.48	67.15	67.53	64.64	71.07	67.32	72.72	70.05	71.42	64.50	74.02	72.23
8	61.13	61.12	68.36	68.11	69.84	69.04	61.93	61.81	59.78	59.50	62.46	63.30
9	85.96	84.49	63.91	63.89	82.10	81.95	86.21	85.12	77.44	77.12	81.20	81.60
10	84.14	68.63	71.95	54.99	88.58	74.11	85.77	72.47	88.61	79.51	85.77	73.47
11	63.93	61.93	64.34	62.28	78.09	77.94	77.45	77.03	82.78	81.02	79.92	80.76
Mean	66.04**	64.35**	70.10*	67.29*	75.83	72.48	72.21*	69.08*	73.96*	70.06*	76.72	72.89
Std.	15.34	14.94	5.99	8.69	8.92	11.38	13.08	13.88	12.86	14.23	8.91	10.74

時でどの部位にどの周波数帯域が活発になっているかを図 3 に示している。疲労状態では、前頭部及び中央




図 3: SADT におけるヒートマップ [8].

部において、低周波数帯域のパワーが増加していることが読み取れる。 α 波は覚醒状態で後頭部中心であり、疲労状態で前頭部に分布してる。

3 研究進捗

3.1 データセットと前処理

提案手法に適用するデータセットとその前処理を提示する。提案手法の評価および実用性の検証に向け、本研究では3つの脳波データセットを用いる。まずはSEED-VLA（実験室環境）およびSEED-VRW（実環境）[9]という2つのデータセットである。SEED-VLAは上海交通大学のBCMIラボ内にある制御された実験室環境にて収集された。この実験セットアップでは屋内に設置された車両のフロントガラスから約2メートル前方に、9枚の小型スクリーンで構成される大型電子スクリーンを配置し、仮想走行ソフトウェアを用いて複雑な道路状況や気象条件をシミュレートした。参加者は20名（男性8名、女性12名、平均年齢21.6歳）であり、合計で100,064秒間の脳波（EEG）データとそれに対応する眼球運動データが取得されている。実地走行環境でのデータセットであるSEED-VRWは同大学の閔行キャンパス外周道路において、実際の走行中にデータを収集した。実験車両には電気自動車を使用され、安全性を確保するために被験者は助手席に座り、経験豊富なドライバーが実際の運転を担当した。被験者の前には、本物に近い運転感覚を再現するためにロジック製のゲーム用ステアリングホイールとペダルが設置されている。走行ルートは主に直線で歩行者の少ないルートを選定し、最高速度を時速30kmに制限するなどの安全対策が講じられた。参加者は14名（男性5名、女性9名、平均年齢20.9歳）であり、合計73,960秒間のデータが蓄積されている。両データセットにおける脳波計測には、DSI-24 乾燥電極脳波キャップが採用された。このデバイスは導電性ジェルや皮膚の事前処理を必要としないため、実際の運転環境下での計測に適している。電極配置は国際10-20法に準拠した18個のチャンネル（Fp1, Fp2, F7, F3, F4, Fz, F8, T3, C3, C4, Cz, T4, T5, P3, P4, T6, O1, O2）が選定された。こちらのデータセットでは実験開始直後の不安定な状態を考慮して記録開始から24秒間のデータを除去し、その後、脳波（EEG）とアイトラッキングのデータ長を短い方に合わせて同期させている。

さらに、運転者の覚醒度推定において広く普及している公開データセットであるSEED-VIG（SJTU Emotion EEG Dataset Vigilance Estimation）も併せて利用する。SEED-VIGは、上海交通大学の脳型計算・知能マシン研究センターによって開発された、運転者の覚醒度推定に特化した公開脳波データセットです。このデータセットは、23名（11名男性、12名女性、平均年齢23.3歳）の被験者を対象とした約2時間の模擬走行実

験を通じて構築されました。信頼性の高いデータを収集するため、実験はサーカディアンリズムにおいて疲労がピークに達する午後13:30頃開始されました。被験者は実験前にカフェイン、タバコ、アルコールの摂取を禁じられています。データ計測にはNeuroscanシステムが用いられ、国際10-20電極法に基づいた計17チャンネルの脳波（EEG）信号と眼電図（EOG）が同時に記録されました。サンプリングレートは200Hzへとて1416000×17のサイズとしている。

これらのデータセットは共通して、疲労状態の客観的な指標となる正解ラベルには、アイトラッキンググラスから得られた「まぶたの閉鎖率」を示すPERCLOSを採用している。PERCLOSは、全時間に対する閉眼時間の割合として定義され、以下の数式を用いて算出される。

$$PERCLOS = \frac{eyeclosingtime}{totaltime} \quad (4)$$

疲労段階としては覚醒状態 ($0 \leq PERCLOS < 0.35$)、疲労状態 ($0.35 \leq PERCLOS < 0.7$)、眠気状態 ($0.7 \leq PERCLOS \leq 1$)と定める。

データセットの前処理として、時間分割を実施した。データを8秒ごとのセグメントに区切り、解析時にはさらに詳細な0.5秒単位の16区間へと分割する。周波数処理においては、バンドパスフィルタを用いることでノイズを除去しつつ、脳波の主要な5つの周波数帯域の信号を抽出する。5つの周波数はδ波 (1-4Hz)、θ波 (4-8Hz)、α波 (8-13Hz)、β波 (13-30Hz)、γ波 (30-45Hz)とした。各周波数帯域最終的な特徴量抽出では、疲労度の指標として最も安定した性質を持つ微分エントロピー（DE）を採用している[10]。各帯域におけるDEは、信号の分散を σ^2 としたとき、

$$DE = \frac{1}{2} \log(2\pi e \sigma^2) \quad (5)$$

という数式を用いて算出される。

3.2 提案手法

本提案手法は、「動的な電極の最適化」に取り組む。図4に全体の流れを提示する。個人やタスクに応じて、電極を最適化することで、精度の向上と計算量の低下を目指す。この手法は、事前に様々な人のデータからどの電極が大切なのかを取得する。そして、動的な電極選択を学習させ、電極の選択の仕方と分類を同時に学習させるようにする。それぞれについて、以下に提示する。



図 4: 提案モデルの流れ.




図 5: 提案モデルの全体像.

3.2.1 電極重要度抽出器モデル

図 5 に電極重要度抽出器モデルの全体像を提示する. このモデルは事前に学習させる必要がある. この事前学習モデルでは, ネットワークを通すことでどの疲労状態の時にどの電極を利用すべきかを学習させることを目的とする. そのため, 出力は疲労分類と利用すべき電極の選定の 2 種類である. 具体的な処理について述べる.

事前学習モデルにおける AI モデルについて述べる. 前処理で得られたデータを入力とする. バッチサイズの中の n 番目を考えることとし, 電極数を E 時間情報を T , 周波数情報を F とする. $X_n \in \mathbf{R}^{E \times T \times F}$ と表される. 始めに, Dilated Convolution を適用した異なる受容野を持つ CNN を作用させることで時系列処理を実施する. カーネルサイズは 3×1 , 5×1 , 9×1 , 17×1 を活用し, 短期・中期・長期・全体の時系列情報を抽出する. 入力を X_n とするとそれぞれの結果は M_{short} , M_{middle} , M_{long} , M_{all} と表せ, それぞれ情報 C が得られたとすると X_{TC} は次のようになる.

$$X_{TC} = \text{concat}(M_{short}, M_{middle}, M_{long}, M_{all}) \quad (6)$$

$X_{TC} \in \mathbf{R}^{E \times 4C \times T \times F}$ という結果になる. X_{TC} は単に各時系列情報を並べているに過ぎないため, 1×1 の Conv を適用することで高度な情報を抽出することができる.

$$X'_n = \text{ReLU}(\text{Conv}_{1 \times 1}(\text{BN}(X_{TC}))) \quad (7)$$

$X'_n \in \mathbf{R}^{E \times C \times T \times F}$ として表される. 次に Attention 機

構を利用し, 疲労に取ってどの情報が周波数情報と時間情報において重要度かを計算する. まずはチャンネルアテンションについて述べる.

$$z_{avg} = \text{AvgPool}(X'_n) \quad (8)$$

$$z_{max} = \text{MaxPool}(X'_n) \quad (9)$$

$$z_{sum} = z_{avg} + z_{max} \quad (10)$$

$$W_{feat} = \sigma(\text{Conv}_{1 \times 1}(\text{Conv}_{1 \times 1}(z_{sum}))) \quad (11)$$

$$X_{feat} = X'_n \odot W_{feat} \quad (12)$$

これにより, channel 間の重要な情報を浮き彫りにすることができる. 次に, 時空間アテンションについて述べる.

$$W_{spa} = \sigma(\text{Conv}_{1 \times 1}(X'_n)) \quad (13)$$

$$X_{spa} = X'_n \odot W_{spa} \quad (14)$$

これにより, 時間-周波数間の重要な情報を浮き彫りにすることができる. これらの情報を最後にまとめる.

$$\begin{aligned} X_{atten} &= X'_n + X_{feat} + X_{spa} \\ &= X'_n \odot (1 + W_{feat} + W_{spa}) \end{aligned} \quad (15)$$

このように, 元の情報を壊さずに重要な情報を増幅するように処理を実施している. そして, CNN+Pooling を利用し, 特徴量を圧縮することで各電極の固定長ベクトルに変換する. 具体的に, X'_n の特徴量を 2 層の CNN を通し, 情報を抽出する. さらに, Adaptive Average Pooling を適用することで特徴量を凝縮した. この結果を I_n とすると $I_n \in \mathbf{R}^{E \times C}$ そして, このベクトルを GNN と Transformer への入力とする. GNN には Graph Transformer を組み込んでいる. このグラフには, 入力情報だけでなく, バイアスを組み込んでいる. このバイアスは電極同士の関係を学習させ, 入力に依らない固定の関係値として追加することで安定した学習を目指す. 本提案の Graph Transformer の構造は, グラフの繋がりを Graph Attention で重要度計算を行い, FFN を利用し, 表現力の向上を狙う仕組みである. また, このグラフの生成方法は相互情報量を活用し, 定めた閾値 (今回は 0.4) を超えた場合にノード同士を結ぶように作成してあり, 図 6 に示す.




図 6: GNN のグラフ.

具体的な処理を以下に示す. 始めに電極同士の attention スコアを計算する. 入力に対して学習可能な重み行列 W を用いて, 線形変換を行いある電極 i が別の電極 j の情報をどれくらい取り入れるべきかを計算する.

$$I'_{n_i} = I_{n_i} W, I'_{n_j} = I_{n_j} W \quad (16)$$

ノードペアの attention を $s_{i,j}$ とし, 学習可能な空間バイアス $B_{i,j}$ を用いる.

$$s_{i,j} = \left(\text{LeakyReLU}(I'_{n_i} + I'_{n_j}) \cdot a \right) \frac{1}{\sqrt{d_k}} + B_{i,j} \quad (17)$$

ここで, a は学習可能なアテンション重みベクトル, d_k は次元数である. 次に, 隣接行列 A がゼロより大きい (つまり繋がりが存在する) エッジのみに注目するようマスキングを施し, アテンション係数 $\alpha_{i,j}$ を Softmax 関数により算出する.

$$\alpha_{i,j} = \text{Softmax}_{j \in \mathcal{N}(i)} (s_{i,j}) = \frac{\exp(s_{i,j})}{\sum_{k \in \mathcal{N}(i)} \exp(s_{i,k})} \quad (18)$$

ここで, $\mathcal{N}(i)$ は隣接行列においてノード i と結合を持つノードの集合を表す. 求めたアテンションを電極情報と計算する. 求められたアテンション係数を用いて周辺ノードの特徴量を集約 (Aggregation) し, Residual 接続と Layer Normalization を適用して中間表現 X_{agg} を得る.

$$X_{agg} = \text{LayerNorm} \left(I_{n_i} + \sum_{j \in \mathcal{N}(i)} \alpha_{i,j} I'_{n_j} \right) \quad (19)$$

最後に, Transformer の典型的な構造と同様に, 各ノードの表現力を非線形に拡大するため Feed-Forward Network (FFN) を適用し, 出力を得る.

$$X_{graph} = \text{LayerNorm} (X_{agg} + \text{FFN}(X_{agg})) \quad (20)$$

上記の処理は Graph Transformer の 1 連を表している. これを 2 層通過してできたベクトルを X'_{graph} とする.

学習可能なパラメータとして E_{emb} を活用して次の式になる.

$$X_{node} = I_n + X'_{graph} + E_{emb} \quad (21)$$

この出力結果を Transformer の Positional Encoding として組み込む. 狙いとして, 通常の Transformer では, 電極間の空間的な特徴を考慮できないため, GNN を利用して得られる空間的な特徴 (電極間の繋がり) を考慮するためである. Transformer 自体は通常のモデルを利用し, エンコーダのみを利用する.

$$X_{input} = \text{concat}(T_{cls}, X_{node}) \quad (22)$$

この操作により, 入力系列の長さは電極数 E に [CLS] トークンを加えた $E + 1$ となり, $X_{input} \in \mathbf{R}^{(E+1) \times C}$ として表される. この関数への入力を X としたとき, Multi-Head Attention の各ヘッド i における Query (Q_i), Key (K_i), Value (V_i) は次のように計算される.

$$Q_i = XW_i^Q, \quad K_i = XW_i^K, \quad V_i = XW_i^V \quad (23)$$

$$\text{Attention}_{weights}^{(i)} = \text{Softmax} \left(\frac{Q_i K_i^T}{\sqrt{d_k}} \right) \quad (24)$$

$$\text{head}_i = \text{Attention}(Q_i, K_i, V_i) = \text{Attention}_{weights}^{(i)} V_i \quad (25)$$

最終的に, すべてのヘッドの出力を結合 (concat) し, 出力用の重み行列 W^O で線形変換することで Multi-Head Attention の出力を得る.

$$\text{MultiHead}(X) = \text{concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (26)$$

上記のアテンション出力を用いて, Transformer Encoder の各層は次のように Residual 接続と Feed-Forward Network (FFN) を経て計算される.

$$X_{mid} = X_{input} + \text{MultiHead}(\text{LayerNorm}(X_{input})) \quad (27)$$

$$X_{out} = X_{mid} + \text{FFN}(\text{LayerNorm}(X_{mid})) \quad (28)$$

ここで FFN は 2 層の全結合層と活性化関数 GELU からなるネットワークであり, 次のように定義される.

$$\text{FFN}(x) = \text{Linear}(\text{GELU}(\text{Linear}(x))) \quad (29)$$

この Encoder 層を L 回 (本研究では $L = 4$) 繰り返した後, 最終層の出力から先頭の [CLS] トークンに対応するベクトル $Z_{CLS} \in \mathbf{R}^{d_{model}}$ のみを抽出する. 最終的な疲労レベルの予測確率 (またはロジット) $\hat{Y}$ は分類器である MLP を通して次のように得られる.

$$\hat{Y} = \text{Linear}(\text{Dropout}(\text{LayerNorm}(\text{Linear}(Z_{CLS})))) \quad (30)$$

本モデルの Transformer エンコーダは、各電極の重要度（寄与度） $Attention_{weights}$ および疲労状態の分類結果 $\hat{Y}$ という2つの出力を生成する。電極の重要度は、Self-Attention 層における Attention 重み（Attention Weights）を平均化することによって算出される。一方、疲労度の分類においては、全電極の情報を集約した [CLS] トークンの特徴ベクトルを抽出し、これを全結合層に入力することで最終的な予測を行う。

3.2.2 電極選択モデル

図7が具体的な学習方法である。以下の順序を通して、学習を進める方法である。

1. 事前学習と学習中のデータ両方から動的に選択。
2. 目標電極数を設け、ペナルティを課して、最適化していく。




図7: 電極選定方法。

この方法には、Gate 機構を導入している。これを導入することで電極の選定方法を学習することができる。選定には、事前学習の結果からどの疲労状態か、どの電極を利用すべきかを活用し、学習可能なパラメータと組み合わせる。これにより、事前学習の結果を参考にしつつ、入力に応じてどの電極が最適なのかを動的に選択することが可能になる。事前に幾つ電極を利用するかを定め、重要度を重み付けされた電極を上位から選択し、バイナリ化する。forward の時のみバイナリ化し、backpropagation 時は小数の値を利用する。電極数を減らすために Gate Loss を加える。式3のような平均二乗誤差を活用する。

$$GateLoss = (\text{使用電極数} - \text{目標電極数})^2 \quad (31)$$

電極数を減らすことと分類精度の向上を目指すために全体 Loss を作成する。式4のような Loss を考慮する。ここで、 r は電極削減の影響をどれだけ強くするかを表す。

$$\text{全体 Loss} = \text{分類 Loss} + r \times GateLoss \quad (32)$$

4 実験結果

4.1 事前学習モデルの結果

学習方法として、バッチサイズを 100、エポック数を 100、損失関数にクロスエントロピー誤差、学習率を 0.001、最適化関数に AdamW を使用し、5 分割クロスバリデーションを実施した。学習結果から順調に学習はしているが、途中から学習が停滞している。この結果を表3に提示する。

表3: 事前学習モデルのアブレーションテスト。

モデル	accuracy	Kappa	Recall	Precision	F1-score
Net	0.8693	0.7860	0.8515	0.8610	0.8561
Graph なし	0.8339	0.7269	0.8070	0.8248	0.8150
Attention なし	0.8666	0.7818	0.8492	0.8583	0.8536
MTC なし	0.8661	0.7808	0.8483	0.8569	0.8524

また、事前学習モデルによる attention の結果を提示する。

表4: 事前学習モデルの attention 結果。

順位	電極	順位	電極	順位	電極
1	O1	7	C3	13	Cz
2	O2	8	T4	14	Pz
3	F8	9	Fp2	15	P3
4	F7	10	T3	16	C4
5	T5	11	Fp1	17	F3
6	P4	12	Fz	18	F4

4.2 電極選択モデルの結果

電極選定方法を活用し、軽量なネットワークを活用した結果を図に提示する。今回適用するネットワークは軽量かつ高性能なアーキテクチャを活用する。EEG-Net[11], EEG-TCNet[12], ATCNet[13] を採用し、検証する。表4の結果を基に固定する電極の選定を行う。3 個の電極を固定させるとしたら、上から順に O1, O2, F8 を固定するようにする。また、本検証では、固定する電極の割合を総電極数の 0%, 25%, 50%, 75%. 小数になる場合には、小数点第一位を四捨五入するようにしている。




図 8: 動的手法適用後の性能評価 EEGNet.




図 9: 動的手法適用後の性能評価 EEGTCNet.




図 10: 動的手法適用後の性能評価 ATCNet.

これらの結果から、本研究の提案手法は分類器に依らず、適した電極を選定することで精度向上に繋がることができている。また、上記結果の中から、EEG-Net を分類器として総電極数を 8 個、固定電極数を 2 個 (25%) とした場合に精度が最も高くなることがわかった。よって、後続の検証ではこれを利用して進めることとする。

改めて、本研究の提案手法を SEED-VLA に適用することで表 5 のような成果を得ることができた。

表 5: 動的手法適用後の性能評価 (SEED-VLA).

モデル	accuracy	Kappa	Recall	Precision	F1-score
固定 2+動的 6	0.8743	0.7939	0.8548	0.8682	0.8611
Random-8	0.8725	0.7914	0.8556	0.8640	0.8596
Full18	0.8359	0.7295	0.8056	0.8308	0.8166
Static Top-8	0.8181	0.6994	0.7845	0.8135	0.7965

図 8 は、本提案手法を利用した場合にどの電極が選定されたかを図示したものである。この図では EEG-Net を分類器として総電極数を 8 個、固定電極数を 2 個 (25%) とした場合である。固定されているため、O1 と O2 はどのタイミングでも採用されている。これを見ると覚醒時には様々な電極を選定しており、脳の様々な部分を利用していることがわかる。一方で疲労状態になってくると、徐々に使用すべき電極が特定されていくことがわかる。Fatigue の状態では前頭葉と後頭葉を採用している。Drowsy の状態では頭頂葉と後頭葉付近を採用している。事前学習の結果から、脳科学から視覚情報が多く得られる部位が後頭葉であることがわかっており、認知力が落ちており、視覚の情報から疲労を検知していることがわかる。さらに、動的な選択から脳の前から徐々に後ろ部分に採用の割合が増えていくことがわかる。




図 11: 電極選択方法による選定される電極のヒートマップ。

4.3 個人差を考慮した解析

LOSO 法により、個人ごとに適応した場合の結果を図 9 に提示する。全体の平均精度は 87.10% になった。




図 12: LOPO 法の結果.

4.4 他のデータセットへ

SEED-VRW と SEED-VIG[14] にも適応した. EEG-Net を分類器として採用し, その結果を提示する.

表 6: 動的手法適用後の性能評価 (SEED-VRW).

モデル	accuracy	Kappa	Recall	Precision	F1-score
固定 2+動的 6	0.8829	0.7899	0.8684	0.8729	0.8705
Random-8	0.8800	0.7843	0.8606	0.8695	0.8649
Full18	0.8505	0.7295	0.8202	0.8418	0.8303
Static Top-8	0.8142	0.6590	0.7650	0.8160	0.7870

表 7: 動的手法適用後の性能評価 (SEED-VIG).

モデル	accuracy	Kappa	Recall	Precision	F1-score
固定 2+動的 6	0.8387	0.7462	0.8435	0.8499	0.8465
Random-8	0.8384	0.7461	0.8454	0.8483	0.8467
Full18	0.8117	0.7034	0.8168	0.8244	0.8204
Static Top-8	0.7862	0.6625	0.7906	0.8015	0.7956

5 考察

本研究では、深層学習を用いた動的な電極の最適化手法を提案した。4章の各結果について言及する。

まず、4.1の事前学習モデルの結果についてである。CNN+Attention+GNN+Transformerによるアーキテクチャでは、全てを組み込むことで最高性能を示すことが可能である。CNNは時間処理をしており、複数のスケールの情報を抽出することでより高い解析をすることに貢献していると考えられる。Attentionは抽出した時間情報と周波数情報からどれに注目すべきかを強調することに貢献していると考えられる。GNNは各電極がどのような関連性があるのかを学習でき、この空間情報が疲労を検知する上で重要だと言える。表4の結果では、後頭葉中心にattentionの値が大きいことがわかる。今回のSEED-VLAではシミュレーションの疲労であるため、視覚情報の疲労が主に影響として考えられるため、脳科学の点においても整合性が取れていると考える。

次に、4.2の電極選択についてである。この結果からは主に3点言及する。1点目は、本提案手法が複数の分類器に対して有効であることだ。今回の検証では3つの分類器を試し、全てにおいて全電極を利用する手法と比較して性能が向上することが読み取れる。しかし、空間情報などを学習するアーキテクチャを分類器として採用する場合には情報が欠如するため、性能が向上しない場合も考えられる。2点目は、提案手法を利用することで適切な電極の選定を実施することが可能であることだ。全電極を利用するのと比較して性能向上を確認できた。これは電極の中にノイズが多い電極や疲労と関係無い電極の排除に成功しているからだと考えられる。また、今回の検証では一部固定+動的な選択が最も効果が高いことがわかった。多くの人の間で汎用的に利用すべき電極と動的な選択は個人や時間の適応が有効だと考えられる。図11の結果から、覚醒状態では広く電極を選定しており、後頭葉を中心として徐々に前頭葉から頭頂葉と電極選定の傾向が変化していることがわかる。覚醒状態では全ての感覚や意識がはっきりしているため、傾向が見られない。一方で、疲労状態に入ると前頭前野の選定が強まる。前頭前野では、意思決定に関連する部位だと考えられており、この部位を注視することで疲労を検知することができると考えられる。さらに、眠気状態だと前頭葉と頭頂葉付近が選定される。前頭葉は作業記憶や運動制御に関連する部位だと考えられている。頭頂葉は感覚を認識する部位だと考えられている。疲労が進むにつれて、この部分の状態の考慮も注視することで疲労検知に有効だと言える。シミュレーション時の運転疲労における今回の学

習による電極の選定と脳科学的知見は整合性の取れる結果だと考える。

次に、4.3の個人差についてである。全体平均精度として87.10%と高い結果を示した。しかし、被験者1と16では低い結果となった。これは疲労のパターンが強い個人差があり、一般的なパターンと異なっている可能性が高いと示唆される。または多くのノイズが混入している可能性も考えられる。

次に、4.4の他のデータセットへの適応についてである。他のデータセットに対しても本提案手法が有効的に働くことがわかる。SEED-VRWはSEED-VLAと電極配置が同じであり、実環境の運転である。実環境に対しても効果があり、実用化への兆しになると考えられる。一方で、SEED-VIGでは全体的に性能が低くなってしまった。原因としては電極配置が異なり、グラフによる解析が適切に処理が適切に実施できていないことによる電極選定の性能低下やデータ量が多いことによる学習困難性が挙げられる。

最後に、本手法の将来性についてである。SEED-VLAに適応した場合、表8のようにまとめることができる。この優れた計算効率と電極選定機能は、次世代の「適

表 8: 性能評価.

モデル	accuracy	Parameters[K]	推論時間 [ms]
EEGNet	0.8359	2.09	0.51
事前学習モデル	0.8693	376	18.13
提案手法	0.8743	382	19.19

応型センシング (Adaptive Sensing)」を実現するための重要な理論的裏付けとなる。具体的には、ゲート機構によって「不要」と判断された電極に対応するAD変換器やフロントエンド回路を一時的にスリープ状態へ移行させることで、システム全体の消費電力を劇的に低減できる可能性がある。被験者の特性や疲労レベルに応じてリアルタイムで計測チャンネルを最小化するこの戦略は、長時間のドライバー監視システムにおけるバッテリー寿命の延長に直結する実用的なアプローチである。

そこで、実際にどの程度計算量を削減できるかを検証する。モデルは事前学習モデルと提案手法の比較をする。実際にどの程度の選択で良いか調査する。選択のトリガーとして、『モデル予測の不確実性 (チャタリング検知)』と『経過時間 (フェイルセーフ)』の2つの基準を組み合わせたハイブリッド型の再選定機構を導入した。具体的には第一の基準として、軽量分類モデルが出力する最大確率が閾値 (0.95) を下回った場合を「予測に自信がない状態」と定義し、直近5ステップ内でその状態が3回検出された際に、被験者の脳波状

態の急変や局所的なノイズによるチャタリングが発生したとみなし、即座に電極の再選定を行う。さらに第二の基準として、不適切な電極構成のままモデルが誤った判断を過信（Overconfidence）し続けることを防ぐため、確信度に関わらず 15 ステップ（120 秒）ごとに強制的な電極の再較正を実施する安全装置（タイムアウト機構）を設けた。その結果として、分類精度 88.83% という高いパフォーマンスを維持したまま、重い特徴抽出・電極選定モジュールの実行回数をわずか全推論の 11.34% にまで削減することに成功した。

$$T = 12,568, \quad T_{noselect} = 1,425, \quad T_{select} = 11,143$$

$$Cost_{事前学習モデル} = T \times FLOPs \quad (33)$$

$$\begin{aligned} Cost_{事前学習} &= 12,568 \times 90.81 \text{ M} \\ &= \mathbf{1,141.25 \text{ G FLOPs}} \end{aligned} \quad (34)$$

$$\begin{aligned} Cost_{提案手法} &= T_{noselect} \times FLOPs_{noselect} \\ &\quad + T_{select} \times FLOPs_{select} \end{aligned} \quad (35)$$

$$Cost_{Baseline} = T \times FLOPs_{Teacher} \quad (36)$$

$$= 12,568 \times 90.81 \text{ M FLOPs} \quad (37)$$

$$= 1,141.25 \text{ G FLOPs} \quad (38)$$

$$Cost_{Proposed} = T_{select} \times FLOPs_{Full} \quad (39)$$

$$\begin{aligned} &+ T_{noselect} \times FLOPs_{EEGNet} \\ &= \underbrace{1,425 \times 91.08 \text{ M}}_{\text{Heavy (11.34\%)}} + \underbrace{11,143 \times 0.26 \text{ M}}_{\text{Lightweight (88.66\%)}} \end{aligned} \quad (40)$$

$$= \mathbf{132.69 \text{ G FLOPs}} \quad (41)$$

$$Reduction = 1 - \frac{132.69}{1,141.25} \approx \mathbf{88.4\%} \quad (42)$$

このように、1 ステップあたり 88.4% の演算を削減することが可能である。ゆえに、事前学習モデルのような計算量の多いモデルを利用し続けるよりも電極選定を行いつつ、軽量モデルで解析することで精度を保ち、大幅に演算量を減らすことが可能になる。

また、プロセッサ内において、演算量よりもデータ移動の方が消費エネルギーが多く、18 個から 8 個に絞ることで 55.6% 削減可能と考えられる。この効果も大きいと考える。

一方で、実用化に向けてはいくつかの課題も残されている。本研究の評価はオフラインの計算機シミュレーションに基づくものであり、実際のモバイルデバイスや組み込みチップ上での電力消費特性、および電極の動的切り替えに伴う回路上のノイズが解析精度に与える影響については今後実機を用いた検証が不可欠である。また、動的な選定処理自体の演算コストが電極削減による省電力効果を相殺しないよう、どのタイミングで選定を実施するかという「再構成のトリガー」の最適化も実装段階における極めて重要な検討事項である。

6 結論

本研究では、CNN-Graph-Transformer を融合した高度な特徴抽出を基に、動的な電極選定をする新たな解析フレームワークを提案した。深層学習の活用により、時間的・個人的に変化する脳波のダイナミクスに応じたチャンネル選択を可能にし、個人最適化された疲労解析の基盤を確立した。複数のデータセットに対しても、手法を適用することで軽量なネットワークであっても十分な性能で解析することが可能である。また、再選定の実行を特定の閾値に基づいたトリガー制御にすることで、計算負荷を最小限に抑える実用的な設計を実現した。今後は、モバイルデバイス等の実機を用いた検証やさらなるモデルの軽量化・高精度化を進め、リアルタイムなドライバー監視システムなどの社会実装に向けた課題を検討していく必要がある。

参考文献

- [1] B. C. Tefft, “Drowsy driving in fatal crashes, united states, 2017–2021,” AAA Foundation for Traffic Safety, Washington, D.C., Research Brief, 2024.
- [2] European Commission, “Road safety thematic report - fatigue,” European Road Safety Observatory, Brussels, European Commission, Directorate General for Transport, Tech. Rep., 2021.
- [3] E. Dagan, O. Mano, G. Stein, and A. Shashua, “Forward collision warning with a single camera,” in *IEEE Intelligent Vehicles Symposium*, 2004, 2004, pp. 37–42.
- [4] O. Ajayi, A. Kurien, K. Djouani, and L. Dieng, “A multimodal systematic review of drivers’

- fatigue detection methodologies, datasets, and models,” *IEEE Access*, 2025.
- [5] L. F. Nicolas-Alonso and J. Gomez-Gil, “Brain computer interfaces, a review,” *sensors*, vol. 12, no. 2, pp. 1211–1279, 2012.
- [6] A. Raza and M. Z. Yusoff, “Deep learning approaches for eeg-motor imagery based bcis: Current models, generalization challenges, and emerging trends,” *IEEE Access*, 2025.
- [7] G. Luo, S. Sun, C. Yan, S. Qu, D. Wang, N. Chu, X. Liu, F. Tian, K. Qian, X. Li *et al.*, “Imgwofs: A feature selector with trade-off between conflict objectives for eeg-based emotion recognition,” *IEEE Transactions on Affective Computing*, vol. 16, no. 2, pp. 598–610, 2024.
- [8] K. Liu, L. Sun, W. Wang, Z. Gu, Z. Yu, and W. Wu, “Mb-stformer: A multi-band spectral-temporal transformer with efficient attention for enhanced eeg-based fatigue detection,” *IEEE Journal of Biomedical and Health Informatics*, 2026.
- [9] Y. Luo, W. Liu, H. Li, Y. Lu, and B.-L. Lu, “A cross-scenario and cross-subject domain adaptation method for driving fatigue detection,” *Journal of Neural Engineering*, vol. 21, no. 4, p. 046004, jul 2024.
- [10] L.-C. Shi, Y.-Y. Jiao, and B.-L. Lu, “Differential entropy feature for eeg-based vigilance estimation,” in *2013 35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE, 2013, pp. 6627–6630.
- [11] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance, “Eegnet: a compact convolutional neural network for eeg-based brain–computer interfaces,” *Journal of neural engineering*, vol. 15, no. 5, p. 056013, 2018.
- [12] T. M. Ingolfsson, M. Hersche, X. Wang, N. Kobayashi, L. Cavigelli, and L. Benini, “Eeg-tcnet: An accurate temporal convolutional network for embedded motor-imagery brain–machine interfaces,” in *2020 IEEE international conference on systems, man, and cybernetics (SMC)*. IEEE, 2020, pp. 2958–2965.
- [13] H. Altaheri, G. Muhammad, and M. Alsulaiman, “Physics-informed attention temporal convolutional network for eeg-based motor imagery classification,” *IEEE transactions on industrial informatics*, vol. 19, no. 2, pp. 2249–2258, 2022.
- [14] W.-L. Zheng and B.-L. Lu, “A multimodal approach to estimating vigilance using eeg and forehead eeg,” *Journal of Neural Engineering*, vol. 14, no. 2, p. 026017, 2017.