

Active BCI における共適応システムの構築に向けた研究 — Test-Time Training を用いたロバストなオフラインモデルの提案 —

5125D028 生川 聖也

1 研究背景

1.1 Active BCI の概要と期待

ブレイン・コンピュータ・インターフェース (BCI) は、脳波 (EEG) などの脳活動信号を用いて、筋力を介さずに外部機器を直接制御する技術である。BCI はその動作原理により、外部からの視覚・聴覚刺激に対する脳の応答を利用するリアクティブ型と、ユーザーの自発的な脳活動を利用するアクティブ型に大別される。

本研究では、ユーザーが「右手を動かす」などの運動想起 (Motor Imagery: MI) を能動的に行うことで操作信号を生成する **Active BCI** を対象とする。Active BCI は、外部刺激装置を必要とせずユーザーの直感的な意図を反映できるため、特に没入感が求められるゲームやエンターテインメント分野への応用が期待されている。

1.2 核心的課題：脳信号の非定常性

Active BCI の実用化を阻む最大の障壁は、脳波信号特有の「**非定常性 (Non-stationarity)**」である。脳波の統計的性質 (分布) は、ユーザーの疲労、集中力の変化、電極のわずかなズレ、あるいは学習効果などにより、同一被験者であっても時間の経過とともに変動する。

これにより、事前に取得した学習データと、運用時に使用するテストデータの間で特徴量の分布が乖離する「**共変量シフト (Covariate Shift)**」が発生する。多くの学習済みモデルは、学習時のデータ分布に最適化されているため、この未知の分布シフトに追従できず、テスト時には著しく分類精度が低下する「**リアリティ・ギャップ**」が生じる。

1.3 本研究の目的：適応的オフラインモデルの構築

上述の課題に対し、本研究全体としてはユーザーとシステムが相互に適応する「**共適応システム**」の実現を目指している。その第一段階として、今期はシステム側の適応能力を高めるための「**ロバストなオフラインモデルの構築**」に焦点を当てた。

具体的には、従来の「静的モデル」では対応できなかった信号の非定常性を動的に補正するため、推論時のテストデータを用いてモデルの内部状態をリアルタイムに更新する **Test-Time Training (TTT)** の概念を導入する。これにより、時間経過による性能低下を抑制し、安定したデコーディングを実現する新たなモデルアーキテクチャを提案・検証する。

2 前提知識

2.1 運動想起 (Motor Imagery) の神経生理学的基盤

本研究で用いる運動想起 (Motor Imagery: MI) は、身体を実際に動かすことなく、脳内で運動をシミュレーションする精神的課題である。MI を行うと、一次運動野および補足運動野において、特定の周波数帯域の脳波パワーが変動することが知られている [1]。

具体的には、運動を想起している最中に、 μ 波 (8–13 Hz) や β 波 (14–30 Hz) のパワーが減少する **事象関連脱同期 (Event-Related Desynchronization: ERD)** が発生する。逆に、想起が終了し安静状態に戻ると、同帯域のパワーが増加する **事象関連同期 (Event-Related Synchronization: ERS)** が観測される。




図 1: 左右の手の運動想起に伴う脳波パワーの空間分布変化 (ERD/ERS) [1]

この ERD/ERS の空間的・時間的なパターンは、想起する身体部位 (右手、左手、足など) によって異なる。

る分布を示す。Active BCIにおける機械学習モデルの役割は、入力された多チャンネルの脳波信号からこれらの特徴的なパターンを抽出し、ユーザーの意図するクラスへ分類することである。

2.2 評価指標

本研究では、構築したモデルの有効性と実用性を評価するため、以下の指標を用いる。

2.2.1 分類性能：コーエンのカッパ係数 (κ)

BCIの多クラス分類タスクでは、クラス間のデータ不均衡や偶然による正解の影響を排除するため、単純な正解率 (Accuracy) に加えて **コーエンのカッパ係数 (Cohen's Kappa coefficient)** を主要な評価指標とする [2]。

$$\kappa = \frac{P_o - P_e}{1 - P_e} \quad (1)$$

ここで、 P_o は観測された正解率、 P_e は偶然による期待一致率である。 $\kappa = 1$ は完全な一致、 $\kappa = 0$ は偶然レベルの分類精度を意味する。一般に、実用的な BCI システムへの移行には $\kappa \geq 0.60$ 程度の性能が推奨される [3]。

2.2.2 リアルタイム性：推論レイテンシ

ゲーミング応用を見据えた Active BCI では、高い応答性が不可欠である。特に本研究では、推論時にモデル更新を行う TTT を導入するため、その計算コストがボトルネックとなるリスクがある。したがって、入力から予測が出力されるまでの処理時間 (Latency) を計測し、アクションゲーム等での利用に耐えうる速度 (例: $< 20\text{ms}$) が維持されているかを検証する。

3 関連研究

3.1 Altaheri らの研究 [4]

Altaheri らは、EEG を用いた運動想起 (MI) デコーディングにおいて、畳み込みニューラルネットワーク (CNN)、Transformer、および時間畳み込みネットワーク (TCN) の利点を統合したハイブリッドモデル **TCFormer** を提案した [4]。




図 2: TCFormer の全体アーキテクチャ [4]。MK-CNN による特徴抽出、Transformer による文脈学習、TCN によるクラス分類の 3 段階で構成される。

3.1.1 Multi-Kernel CNN (MK-CNN)

入力層には、異なる時間スケール (カーネルサイズ: 20, 32, 64) を持つ並列畳み込み層が配置されている (図 3)。




図 3: Multi-Kernel CNN の詳細 [4]。複数のカーネルで並列処理を行うことで、異なる周波数帯域の特徴を同時に抽出する。

3.1.2 Transformer Encoder with GQA

MK-CNN によって抽出された特徴トークン列は、Transformer Encoder に入力され、Self-Attention 機構を用いて系列全体の大域的な依存関係 (Global Context) が学習される。TCFormer では計算効率と精度のバランスを最適化するため、図 4 に示す **Grouped-Query Attention (GQA)** を採用している。




図 4: Attention 機構の比較 [4]. (左) MHA, (中) MQA, (右) GQA. GQA は MHA の表現力と MQA の効率性を両立させる.

3.1.3 Temporal Convolutional Network (TCN)

Transformer の出力に対して, 図 5 に示す Dilated Causal Convolution (拡張因果畳み込み) を用いた TCN を適用する.




図 5: TCN の残差ブロック構造 [4]. 拡張畳み込みにより受容野を広げる.

3.1.4 研究結果

BCI Competition IV-2a データセット (9 名, 4 クラス MI) を用いた評価結果を表 1 に示す. TCFormer は平均精度 **84.79%**, カップ係数 **0.80** を達成し, SOTA 性能を示している [4].

表 1: BCI Competition IV-2a における各モデルの精度比較 (Within-Subject) [4]

Model	Accuracy (%)	Kappa
EEGNet [5]	72.62	0.64
ShallowNet [6]	65.72	0.54
EEG-TCNet [7]	78.82	0.72
ATCNet [8]	83.78	0.78
TCFormer (Proposed)	84.79	0.80

3.2 Sun らの研究 (Test-Time Training) [9]

Sun らは, 系列データのモデリングにおいて, 従来の RNN や Transformer が抱える「固定された隠れ状態」や「計算量の増大」という課題を解決するため, 新たなフレームワーク **Test-Time Training (TTT)** を提案した [9].




図 6: TTT 層の概念図 [9]. 隠れ状態をモデルの重み W とみなし, 入力 x_t ごとに自己教師あり学習で更新する.

3.2.1 TTT-Linear と Dual Form による高速化

本研究では, Sun らが提案した **TTT-Linear** を採用する. これは内部モデルを線形モデル $z = Wx$ としたものであり, **Dual Form (双対形式)** と呼ばれる数理的なトリックを用いることで, 勾配計算と重み更新を高速な行列演算に変換できる [9].





図 7: TTT の計算グラフ [9]. Dual Form を用いることで, 中間の重み (白いノード) を顕在化させずに, 入力から出力 (黄色いノード) を効率的に計算できる.

4 研究進捗：モデルの改良プロセス

本章では, ベースラインモデルの課題特定から, TTT の導入, そしてハイブリッドアーキテクチャの確立に至るまでのプロセスを述べる.

4.1 実装詳細

本実験の実装には PyTorch 2.0 を使用し, 最適化手法には AdamW を採用した. 学習率は 1×10^{-3} , 重



(a) Subject 2 (Failure)

(b) Subject 6 (Stable)

図 8: 学習曲線の比較. (a) S2 は Train と Val の乖離が大きく過学習傾向にあるのに対し, (b) S6 は安定して学習できている.

み減衰は 1×10^{-2} とし, TTT 層における内部ループの学習率 (Base LR) は 0.1, 正則化係数 λ は 0.01 に設定した. すべての実験は同一の計算機環境 (GPU: NVIDIA RTX A6000 想定) 上で実行し, 乱数シードを固定して再現性を確保した.

4.2 Phase 1: ベースライン評価と課題の特定

まず, SOTA モデルである TCFormer (Base モデル) を BCI Competition IV-2a データセットに適用し, その性能を検証した. 表 2 に被験者ごとの分類精度を示す. 全体の平均精度は 84.7% と高水準であるが, **Subject 2** の精度が **63.8%** と、他と比較して著しく低いことが確認できる.

表 2: ベースラインモデル (TCFormer) の被験者別精度. Subject 2 のみが特異的に低い値を示している.

Subject	1	2	3	4	5
Accuracy (%)	91.4	63.8	89.7	84.5	74.1
Subject	6	7	8	9	Mean
Accuracy (%)	86.2	94.8	86.2	91.4	84.7

- **原因分析:** 図 8 に学習曲線を示す. Subject 2 (左) は学習データには適応しているものの, 検証データ (別セッション) に対して適応できておらず, 乖離が大きい. これはセッション間の非定常性による「過学習」を示唆している.

4.3 Phase 2: TTT による完全置換 (Pure TTT)

非定常性への対策として, 図 9 に示すように, TCFormer の Attention 層を TTT 層に完全に置き換えた

モデル (Pure TTT) を構築した. 推論時に重みを更新することで, 分布シフトへの追従を試みた.




図 9: Phase 2: Pure TTT モデルの処理フロー. Attention 層を TTT 層に置換し, 推論時に全トークンで重み更新を行う.

4.3.1 結果と新たな課題

S2 の精度は **69.0% (+5.2%)** へと向上したが, 安定した Subject 6 などの精度が低下した. 図 10 に示すように, Pure TTT (中央) では安定した特徴空間を無理に更新し, Base モデル (左) できれいに分かれていたクラス構造を破壊する「過剰適応 (Over-adaptation)」が発生した.




図 10: Subject 6 の特徴空間比較. (左) Base モデルは分離しているが, (中) Pure TTT では過剰適応により構造が破壊されている. (右) Hybrid では安定性が維持されている.

4.4 Phase 3: Hybrid Residual TTT (最終解)

「安定性」と「適応性」を両立させるため, 図 11 に示すハイブリッドアーキテクチャを提案する. 固定された Attention 層 (Main Path) に対して, 軽量化した TTT 層 (Adapter Path) を並列に追加し, 学習可能な係数 α で統合する. Main Path が「アンカー」として機能し, Adapter Path が必要な場合のみ補正を加える構造である.

4.4.1 Adapter Path の工夫

Adapter Path は, 計算コストを抑えつつ効果的に適応を行うため, 図 12 に示す独自の設計を採用した.




図 11: Phase 3: 提案手法 Hybrid Residual TTT の処理フロー．静的な Main Path と動的な Adapter Path を並列化し，残差結合する．




図 12: TTT Adapter の詳細構造．Down/Up-Projection によるボトルネック構造と，Zero-Init による学習安定化を導入している．

1. **ボトルネック構造:** TTT 層の前後に次元圧縮・復元を配置し，中間次元を $1/4$ に削減することで，勾配計算コストを大幅に低減した．
2. **ゼロ初期化 (Zero-Init):** 係数 α を 0 で初期化することで，学習初期は安定した Base モデルとして振る舞い，必要な分だけ TTT の補正を取り込む挙動を実現した．
3. **Dual Form の採用:** TTT 層の計算に Dual Form を採用し，推論時の重み更新を行列演算のみで高速化した．

4.4.2 定量評価：精度の向上と維持

図 13 に全被験者の精度比較を示す．Subject 2 において $+10.3\%$ の大幅な改善 (74.1%) を達成しつつ，Subject 6 などの高精度層も維持しており，全体としてロバスト性が向上した．




図 13: 全被験者における分類精度の比較 (Base vs Hybrid)．S2 の大幅改善に加え，他被験者でも性能低下を最小限に抑えている．

表 3 に，TCFormer (Base)，Pure TTT，Hybrid の 3 モデルにおける被験者別精度とカッパ係数を示す．提案手法である Hybrid モデルは，ターゲットとした Subject 2 において Base モデル比で $+10.3\%$ ($63.8\% \rightarrow 74.1\%$) の精度向上を達成した．これはカッパ係数においても 0.52 から 0.66 への改善として現れており，ランダムな正解ではなく実質的な分類能力の向上を示している．また，Pure TTT では Subject 6 などで精度低下が見られたが，Hybrid モデルでは Base モデルと同等の水準を維持しており，提案したアーキテクチャが適応性と安定性のバランスを適切に取れていることが確認できる．

4.4.3 定性評価：特徴空間の改善

図 14 に Subject 2 の特徴空間を示す．Base モデル (左) ではクラスが混在していたが，Hybrid モデル (右) では TTT の効果により明確な分離が実現されている．

表 3: 各手法における被験者別分類精度 (Acc) とカッパ係数 (Kap) の比較. 提案手法 (Hybrid) は, S2 における顕著な改善を示しつつ, Base モデルの安定性を維持している.

Subject	Base (TCFormer)		Pure TTT		Hybrid (Proposed)	
	Acc (%)	Kappa	Acc (%)	Kappa	Acc (%)	Kappa
S1	91.4	0.89	77.6	0.70	77.6	0.70
S2 (Target)	63.8	0.52	69.0	0.58	74.1	0.66
S3	89.7	0.86	89.7	0.86	86.2	0.82
S4	84.5	0.79	77.6	0.70	81.0	0.75
S5	74.1	0.65	70.7	0.61	74.1	0.65
S6	86.2	0.82	89.7	0.86	84.5	0.79
S7	94.8	0.93	87.9	0.84	93.1	0.91
S8	86.2	0.82	79.3	0.72	89.7	0.86
S9	91.4	0.89	84.5	0.79	82.8	0.77
Mean	84.7	0.80	80.7	0.74	82.6	0.77




図 14: Phase 3 の成果: Subject 2 の特徴空間. Base モデル (左) の混在状態から, Hybrid モデル (右) では明確なクラス分離を実現した.

4.4.4 計算コストの評価

図 15 に推論レイテンシの比較を示す. Hybrid モデルは TTT を追加しているが, ボトルネック構造により計算増加はわずかであり, 平均 **7.6ms** で推論可能である. これはアクションゲームの許容ライン (20ms) を十分に下回っている.




図 15: 推論レイテンシの比較. Hybrid モデルはリアルタイム動作可能な速度を維持している.

5 今後の展望

5.1 パラメータ最適化による不確実性の抑制

本手法により S2 をはじめとする多くの被験者で改善が見られたが, Subject 1 においては精度が低下した. 図 16 のエントロピー分布を見ると, 高精度だった Base モデル (青) は低エントロピー側に集中しているのに対し, Hybrid モデル (赤) は高エントロピー側へシフトしている.

これは, S1 のように Base モデルで既に決定境界が最適化されているケースにおいて, TTT による動的な重み更新が**過剰な修正 (Over-correction)**として働き, かえってモデルの判断に「迷い (不確実性)」を生じさせたと考えられる. 今後は, Main パス (固定重み) の信頼度が高い場合には Adapter パス (適応) の影響を弱めるような, **信頼度に基づく動的なゲーティング機構**や, 正則化項の強化 (Plan A) を導入し, 安定性と可塑性のトレードオフを最適化する.




図 16: Subject 1 における予測エントロピー. Hybrid モデル（赤）はエントロピーが増大しており、予測の不確実性が高まっている。

5.2 オンライン・クローズドループ環境の構築

図 17 に示すシステムを構築し、Python（推論）と Unity（ゲーム）を LSL で接続する。提案モデルの実機環境における有効性と、ユーザー体験（UX）への影響を検証する。




図 17: 構築予定のオンライン実験システム（LSL 接続）。Python 上の Hybrid モデルと Unity 上のゲーム環境を双方向に接続し、リアルタイムな適応とフィードバックを実現する。

6 今後の予定

6.1 短期：パラメータの最適化

Subject 1 で見られた「不確実性の増大」を防ぐため、TTT の学習率（Base LR）や正則化係数（Regularization）のチューニングを行う。具体的には、適応の「ブレーキ」を強めることで、Main パスの判断をより尊重する設定（Plan A）を検証する。

6.2 中期：オンライン環境での実証

構築した Hybrid モデルをリアルタイム環境へ移行する。

1. Python 上での疑似オンラインループによる推論速度の検証（目標：レイテンシ < 20ms）。
2. Unity と Lab Streaming Layer (LSL) を用いたクローズドループ環境での動作実証。

これにより、提案モデルが実際のゲームプレイ環境においても有効に機能することを示す。

7 結言

本研究では、脳波の非定常性を克服するため、Test-Time Training を用いた適応的オフラインモデル **Hybrid Residual TTT** を提案した。実験の結果、従来モデルでは困難であった被験者の精度を **+10.3%** 向上させつつ、安定した被験者の性能低下を防ぐことに成功した。今後はパラメータの最適化を経て、実用的なオンライン共適応システムの実現を目指す。

参考文献

- [1] G. Pfurtscheller, C. Brunner, A. Schlögl, and F. L. Da Silva, “Mu rhythm (de)synchronization and EEG single-trial classification of different motor imagery tasks,” *NeuroImage*, vol. 31, no. 1, pp. 153–159, 2006.
- [2] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [3] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” *Biometrics*, pp. 159–174, 1977.
- [4] H. Altaheri, F. Karray, and A.-H. Karimi, “Temporal convolutional transformer for EEG based motor imagery decoding,” *Scientific Reports*, vol. 15, no. 1, p. 32959, 2025.
- [5] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance, “EEGNet: a compact convolutional neural network for EEG-based brain–computer interfaces,” *Journal of Neural Engineering*, vol. 15, no. 5, p. 056013, 2018.

- [6] R. T. Schirrmeister, J. T. Springenberg, L. D. Fiederer, M. Glasstetter, K. Eggersperger, M. Tangermann, F. Hutter, W. Burgard, and T. Ball, “Deep learning with convolutional neural networks for EEG decoding and visualization,” *Human Brain Mapping*, vol. 38, no. 11, pp. 5391–5420, 2017.
- [7] T. M. Ingolfsson, M. Hersche, X. Wang, N. Kobayashi, L. Cavigelli, and L. Benini, “EEG-TCNet: An accurate temporal convolutional network for embedded motor-imagery brain-machine interfaces,” in *2020 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*. IEEE, 2020, pp. 2958–2965.
- [8] H. Altaheri, G. Muhammad, and M. Alsulaiman, “Physics-informed attention temporal convolutional network for EEG-based motor imagery classification,” *IEEE Transactions on Industrial Informatics*, vol. 19, no. 2, pp. 2249–2258, 2023.
- [9] Y. Sun, X. Wang, Z. Liu, J. Miller, A. Efros, and M. Hardt, “Test-time training with self-supervision for generalization under distribution shifts,” in *International Conference on Machine Learning*. PMLR, 2020, pp. 9229–9248.