

Active BCIにおける共適応システムの構築に向けた研究

Test-Time Trainingを用いたロバストなオフラインモデルの提案

定期ゼミ

史研究室 M1

生川 聖也

2025年12月19日

アウトライン

- 研究背景
- 研究目的
- 関連研究
- 提案手法
- 評価実験
- 考察
- 今後の展望
- 今後の方針

研究背景

Brain-Computer-Interface(BCI)とは？

→脳活動で機械を直接操作する技術

その動作原理から3つに分類される

1. Active BCI: ユーザーが意図的に脳を活動させて操作する
2. Reactive BCI: 外部刺激への脳の応答を利用する
3. Passive BCI: ユーザーの認知状態をモニタリングする

本研究は、能動的な制御を行う Active BCI に焦点を当てる

研究背景

Active BCIの応用は、主に2つに分けられる

- 機能回復 (Restoration):
 - 重度運動機能障害を持つ人々のための支援技術
- 体験拡張 (Augmentation):
 - 「新規性」や「娯楽性」を追求



図. 脳波によるゲーム操作[1]

本研究は後者の「体験拡張」、特にゲーム分野に焦点を当てる

研究課題

Active BCIの実用化には、複数の課題が存在

1. オフライン-オンライン性能の乖離（リアリティ・ギャップ）
 - 最も深刻な問題。事前データでの高い性能が、リアルタイム環境では再現できない現象
2. BCI非効率性 (BCI Inefficiency)
 - 全てのユーザーがBCIを効果的に利用できるわけではない問題
 - 従来のモデルが想定する**典型的な脳活動パターンを生成しない**ユーザーが存在することに起因する
3. キャリブレーションの負荷
 - 多くのシステムで、ユーザー毎に必要となる**長く単調な事前データ収集**が実用上の大きな障壁

研究目的

提示した3つの課題に対し、2つの技術的アプローチで解決に挑む

➤ ロバストなオフラインモデルの構築 (Step 1)

- 目的: 個人差やデータ量の問題を解決する、頑健な基礎モデルを構築
- 解決する課題:
 - 課題 BCI非効率性:
 - **個人差に強い汎用モデルで、より多くのユーザーに対応**
 - 課題 キャリブレーション負荷:
 - 少ないデータでも学習可能なモデルで、事前準備の負荷を軽減

今回のターゲット

➤ オンラインでの強化学習による適応 (Step 2)

- 目的: リアルタイムでの脳波の変動に対応し続ける、適応能力を獲得
- 解決する課題:
 - 課題① リアリティ・ギャップ:
 - ErrPを報酬信号とし、システムが常にユーザーに追従し続けることで、性能の乖離を埋める

関連研究： Altaheriらの研究

TCFormer (Temporal Convolutional Transformer)[2]

→CNN・Transformer・TCNの強みを統合したハイブリッドモデル




図. TCFormer アーキテクチャ[2]

関連研究： Altaheriらの研究




図. TCFormer アーキテクチャ[2]

関連研究： Altaheriらの研究

モジュール詳細① - マルチカーネル畳み込み (MK-CNN)

3つの並列カーネルで異なる時間スケールのパターンを同時抽出




図. TCFomerにおける階層的特徴学習パイプライン[2]

関連研究： Altaheriらの研究

モジュール詳細② -Transformer

計算効率化: グループ化クエリ注意 (GQA)

- Multi-Head AttentionとMulti-Query Attentionの最適バランス
- 従来比1/4の計算コストで同等の表現力を実現




図. アテンションの比較[2]

関連研究： Altaheriらの研究

モジュール詳細③ -時系列畳み込みネットワーク (TCN)

TCNによる時系列モデリングの強化

拡張畳み込み (Dilated Conv)： 少ない層数で広い範囲の時間情報を集約

因果性の維持 (Causality)： 時系列の順序を崩さず、過去から現在への情報の流れのみを学習

残差ブロック (Residual Block)： 深層化に伴う学習の不安定性を解消し、収束を促進




図. TCNの処理フロー[2]

関連研究：Sun et al.らの研究

Test-Time Training (TTT)[3]

概要： テストデータ（推論時の入力）を用いて、推論時にもモデルを更新する手法

- 自己教師あり学習（補助タスク）を導入し、ラベルのないテストデータから特徴表現を最適化
- 学習時とテスト時の分布ズレに適応し、汎化性能を向上させる




図. Test-Time Training (TTT) の概念図[3]





図. 勾配の並列計算と双対形による効率化プロセス[3]

関連研究：Sun et al.の研究


「系列データの圧縮（記憶）＝モデルの学習」と捉え直す

→「学習する方法」を学習する


通常の学習 (Standard)



TTTの学習 (Meta-Learning)



従来の RNN



TTT (Test-Time Training)




図. TTTの学習、推論時の概要

研究のアプローチ（3つのフェーズ）

Phase 1：ベースライン評価（課題の特定）

Phase 2：Pure TTTの試行（完全置換）→ 過剰適応の発覚

Phase 3：Hybrid TTT（提案）で安定性と適応性を両立



ゴール：非定常性に強い「共適応」システムの土台を作る

データセット：BCI Competition IV Dataset 2a

概要

名称：BCI Competition IV Dataset 2a (BCIC IV-2a)

被験者：健常者9名 (Subject 1-9)

タスク：4クラス運動想起 (4-class Motor Imagery)

左手 / 右手 / 両足 / 舌

データ仕様

チャンネル：EEG 22ch (10-20法) + EOG 3ch

サンプリングレート：250 Hz

フィルタ：0.5-100 Hz バンドパ




図. パラダイムのタイミング計画[4]




図. 電極配置[4]

Phase 1：ベースライン評価と課題

ベースラインモデル(TCFormer)[2]を再現

BCIC IV-2a (9名), Within-Subject評価

平均 84.7% と高精度だが、Subject 2 (63.8%) のみ極端に低い




図 5：学習曲線 (Subject 2)




図 6：学習曲線 (Subject 6)

課題：S2は「学習→推論」の分布ズレが大きく、静的モデルでは救えない

Phase 1：特徴空間の課題（Subject 2）

クラス分離の困難性： t-SNE上で各クラスが混在し、明確なクラスタを形成できていない

精度への影響： 特にFeetとHand(L)の相互混同が激しく、識別性能が低下している

対策： Subject 2特有のデータ分布に対し、**TTTで特徴表現を動的に適応させる**




図. 特徴空間（t-SNE）：Base




図. クラス間の混同状況（Subject 2）

Phase 2 : Pure TTTによる完全置換




図. Pure TTT（完全置換）の処理フロー

Phase 2 : Pure TTTによる完全置換

Subject	Base	Pure TTT
S1	91.4	77.5
S2	63.8	69.0
S3	89.7	89.9
S4	84.5	77.5
S5	74.1	70.8
S6	86.2	89.9
S7	94.8	87.8
S8	86.2	79.5
S9	91.4	84.7
Mean	84.7	80.7

課題としていたsubject2の精度は向上
しかし、ほとんどの精度が悪化




図. S1におけるBaseとTTTの比較

結論：「適応性」と同時に「安定性」を設計に組み込む必要がある

Phase 3 : 提案手法 Hybrid Residual TTT

並列ハイブリッド構造で「安定性」と「適応性」を両立

- Main Path (Attention) : 固定重みで普遍的特徴を維持 (アンカー)
- Adapter Path (TTT) : 推論時更新で個人差・ズレを補正
- 残差結合 (+) で統合 : 必要な分だけ適応を取り込む




図. Hybrid アーキテクチャ

Phase 3 : 提案手法 Hybrid Residual TTT

Hybrid Encoder (Parallel Residual)

$$H' = H + \text{Attn}(\text{Norm}_1(H)) + \alpha \cdot \text{TTT_Adapter}(\text{Norm}_1(H))$$
$$H_{\text{out}} = H' + \text{MLP}(\text{Norm}_2(H'))$$

※ α (adapter_scale) は学習可能 / Zero-init (初期0) で安定化




図. Hybrid アーキテクチャ

Phase 3 : 提案手法 Hybrid Residual TTT

ボトルネック構造：次元を1/4に圧縮 → TTT → 復元（計算量削減）

Zero-Init：スケール係数 α を0で初期化し、必要な分だけ適応を取り込む

Dual Form：重み更新を行列演算に置換して高速化




図. TTT Adapterの構造

実験結果

Subject 2 : Base 63.8% → Hybrid 74.1% (+10.3%)

高精度層（例：S6, S7）の性能崩壊を回避（Pure TTTの課題を改善）




図. 精度比較（全被験者）

ポイント：S2の大幅改善 + 他被験者の性能低下を最小化

実験結果

Subject	Base	Pure TTT	Hybrid
S1	91.4	77.5	77.5
S2	63.8	69.0	74.1
S3	89.7	89.9	86.2
S4	84.5	77.5	81.1
S5	74.1	70.8	73.9
S6	86.2	89.9	84.7
S7	94.8	87.8	93.5
S8	86.2	79.5	89.9
S9	91.4	84.7	82.6
Mean	84.7	80.7	82.6

S1のみ大幅に精度悪化

S2 : Accuracy +10.3pt

Kappa : 0.52 → **0.66** (改善)

※実用目安 : $\kappa \geq 0.60$

実験結果

Base（左）：クラスが混在

Hybrid（右）：TTTの補正によりクラス分離が明確化




図. 特徴空間（t-SNE）比較：Base vs Hybrid

証拠：特徴空間が整理され、分布ズレに適応できた

実験結果

Base（左）：feet, hand(L)の精度がかなり低い

Hybrid（右）：TTTの補正により精度向上




図.Baseモデルのクラス間の混同状況 (Subject 2)




図.Hybridモデルのクラス間の混同状況 (Subject 2)

推論レイテンシの評価（リアルタイム性）

Hybridモデル：推論時間 約 7.6 ms

ボトルネック構造 + Dual Formにより高速性を維持

アクションゲーム要件（< 20ms）を十分クリア




図. 推論レイテンシ比較

TTT導入でも「実時間動作」可能な計算コスト

考察と課題：Subject 1の精度低下

Subject 1：91.4% → 77.6% と精度低下が発生

エントロピー分析：Hybridの分布が高エントロピー側へシフト

Baseで最適だった決定境界を動かし、不確実性（迷い）が増加した可能性




図. エントロピー分布 (Subject 1)

エントロピーの解釈（確率分布の質）

Baseモデル：低エントロピー（迷いが無い）

→ 誤答時でも確率分布が鋭く尖る状態

Hybridモデル：高エントロピー（迷いを許容）

→ 確率分布が平坦化し、慎重に推論する状態

トレードオフ：

• S1では、この慎重さが「不必要な迷い」となり精度低下

今後の展望 1：動的ゲーティングで適応を制御

迷っている時だけTTTを作動（S1の“余計な摂動”を回避）



現状：Static α （固定） → 提案：Dynamic α （確信度でON/OFF）

今後の展望 2：オンラインシステム構築

次フェーズ：実機（Unicorn）を用いたリアルタイム実験

- Python（推論・適応） $\leftrightarrow$ LSL $\leftrightarrow$ Unity（ゲーム）でクローズドループ環境を構築
- 性能だけでなくUX（操作感・疲労）まで評価





図. オンラインシステム構成（Python×LSL×Unity）

今後の方針

	12月	1月	2月	3月	4月	5月	6月
論文調査							
オフラインモデル実装							
Unity実装							
オンライン環境構築							
オンライン強化学習							

参考文献

- [1] g.tec medical engineering GmbH, "Controlling World of Warcraft with the Brain-Computer Interface," <https://www.youtube.com/watch?v=SWlgzA32s4c>, 2011, YouTube video. Accessed: 2025-06-24.
- [2] H. Altaheri, F. Karray, and A.-H. Karimi, "Temporal convolutional transformer for EEG based motor imagery decoding," *Scientific Reports*, vol. 15, 32959, 2025.
- [3] Sun, Y., Li, X., Dalal, K., Xu, J., Vikram, A., Zhang, G., Dubois, Y., Chen, X., Wang, X., Koyejo, S., Hashimoto, T., & Guestrin, C. (2025). Learning to (learn at test time): RNNs with expressive hidden states. arXiv preprint arXiv:2407.04620.
- [4] Brunner, C., Leeb, R., Müller-Putz, G. R., Schlögl, A., and Pfurtscheller, G. "BCI Competition 2008 – Graz data set A." Institute for Knowledge Discovery, Graz University of Technology, 2008.