

第二回班ゼミ

史研究室 M2
生川 聖也


アウトライン

- 1 背景・目的
- 2 前回までの進捗
- 3 提案：Replay-SafeCommit
- 4 実験結果
- 5 論文調査：BT TA-DG
- 6 今後の方針

1. 背景・目的

背景：EEG-MI では session 間の分布ずれにより分類性能が低下する

- EEG-MI は、脳波から運動想起クラスを分類する BCI タスクである
- 同じ被験者でも、日や session が変わると EEG 特徴分布が変化する
- そのため、session_T で学習した分類器を session_E にそのまま適用すると性能が低下しやすい



背景課題：EEG-MI の実用化には、session ごとの分布ずれに頑健な分類が必要である。

問題：OTTA は分布ずれに追従できる一方、誤更新で性能劣化を招く

- OTTA は、target session の unlabeled stream を用いてモデル逐次更新する
- 分布ずれに追従できる一方、EEG は高信頼予測が正解とは限らない
- 誤った trial で更新するとモデル状態が汚染され、以降の trial でも誤分類が起きやすくなる



OTTA では「更新するか」だけでなく、「何を・いつ更新するか」を安全に決める必要がある。

目的：平均精度向上と、被験者単位の悪化抑制を両立する

BCI では、平均精度が上がっても一部の被験者で大きく悪化する手法は使いにくい。
そのため、本研究では「**全体として良くなるか**」と「**誰かを大きく悪化させていないか**」を分けて評価する。


指標	見るもの	解釈
平均精度	全被験者平均の精度	全体性能
Δ vs source_only	適応なしからの改善幅	OTTA の上乗せ効果
worst Δ	最も悪化した被験者の変化量	最悪ケースの確認
HSC	0.5pp以上悪化した被験者数	被験者単位の悪化

2. 前回の振り返り

shallow 側の分散更新が，一部被験者の大幅悪化要因になった

これまでの検証により、被験者2の場合「shallow × var only」を更新した際に大幅に精度が悪化
→浅層分散(shallow × var only)を不用意に更新しない方針が見えた。

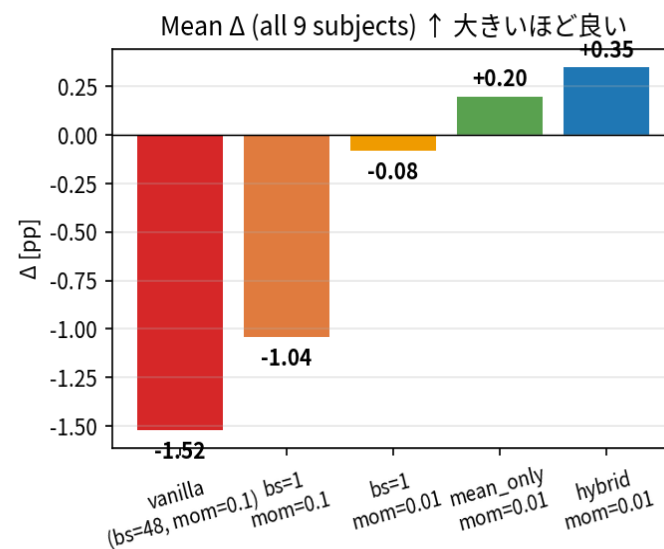


2×2 direction ablation: S2 の harm は shallow × var にほぼ局在
同じ操作(shallow var)が S7 では gain、S2 では harm → 被験者依存の方向




前回は固定ルールで、被験者単位の悪化を抑える方向性を確認した

- どの被験者も大幅に壊れていない
- 平均も改善側へ

OTTA 設計の進化：vanilla → hybrid で material harm を全被験者で排除 (0/9) かつ平均改善



固定ルールでは、被験者や入力に応じた更新方法の切り替えができない



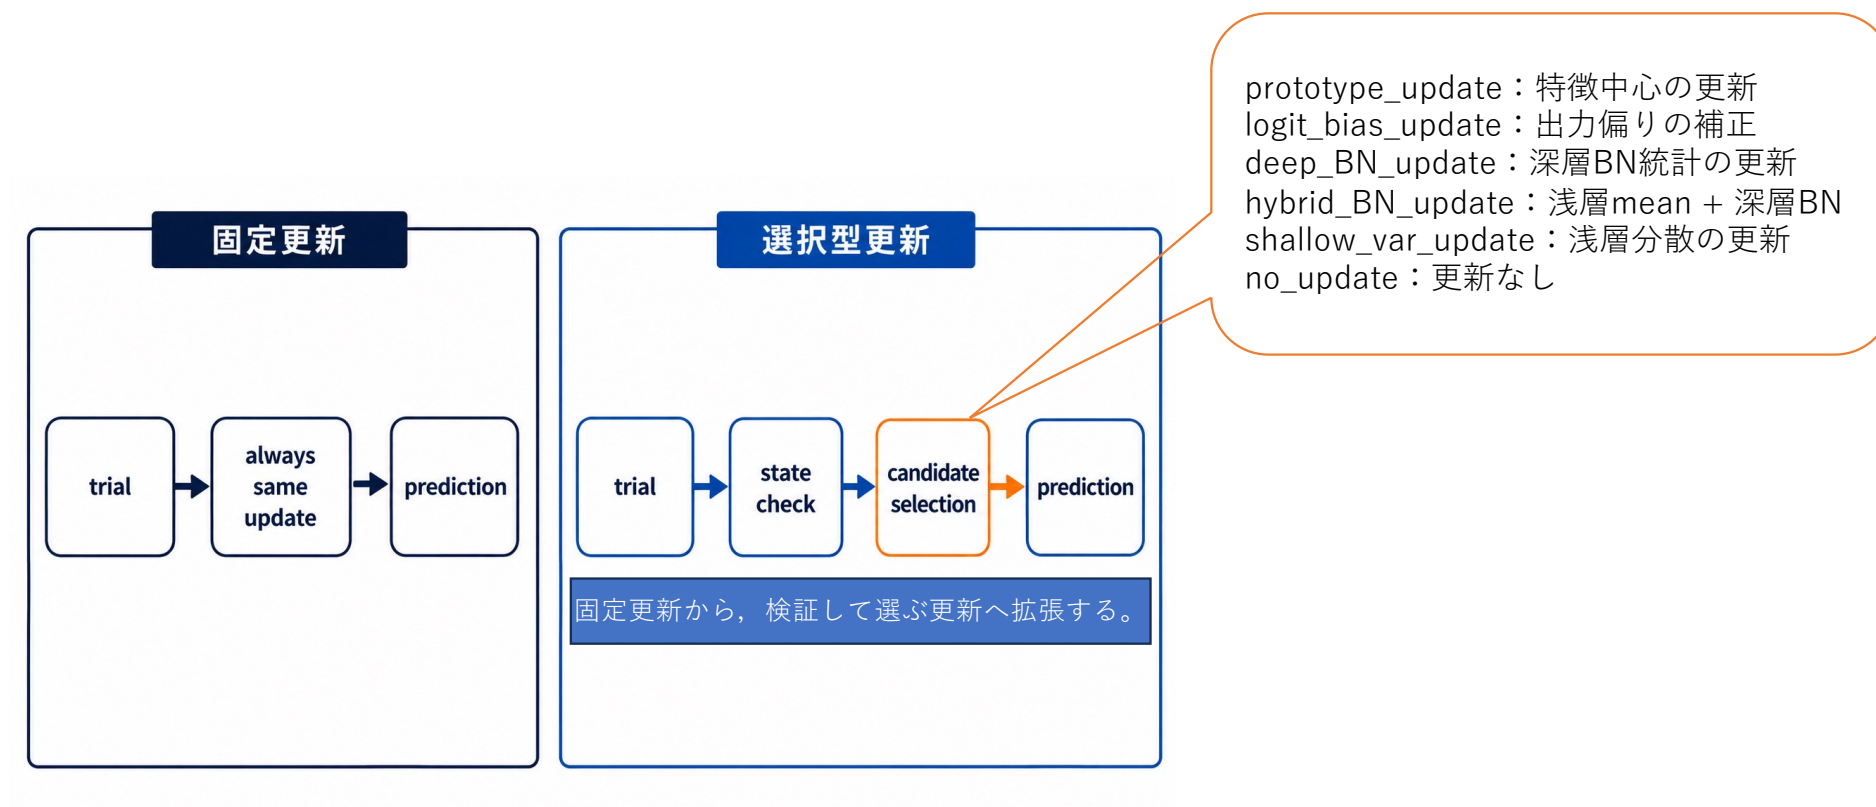
固定ルールで拾えない差	具体例	必要になる判断
被験者差	BN 更新が効く被験者もいれば、悪化する被験者もいる	被験者状態に応じて更新方法を変える
入力差	prototype 更新が安全な入力があれば、更新しない方がよい入力もある	1回の入力ごとに採用可否を判断する

被験者、入力に応じて選択できるようにしたい

提案：Replay-SafeCommit

固定更新ではなく、候補更新を検証してから採用する

- 前回：1つの更新ルールを固定的に適用
- 今回：複数の更新候補を用意し，採用前に安全性を確認



候補更新は、過去の高信頼入力で安全性を確認してから採用する

■ replay buffer

過去の高信頼な入力を保存した小さな検証用集合

候補更新を仮適用した後、
この集合で予測が悪化しないか確認する

Replay-SafeCommit 概略



過去の高信頼入力を小さな検証集合として使い、危険な更新は採用せずに巻き戻す。

過去の高信頼入力で、候補更新の悪影響を確認する


■ replay buffer の中身

- ・ 過去の高信頼な入力を最大32件保存
- ・ 各入力には、その時点の予測ラベルを保持

■ 候補更新の評価

- ・ 候補更新を仮適用する
- ・ 更新前後で replay buffer を再推論する
- ・ 悪化しなければ commit, 悪化すれば rollback

リプレイバッファ評価の仕組み



未来の入力で悪化するかは直接見られないため、過去の高信頼入力を小さな検証集合として使う。

sim_score は、過去の高信頼入力への悪影響を3つの観点で評価する

3/6 提案

sim_score > 0 : 採用
sim_score ≤ 0 : 棄却して巻き戻し

$$\text{sim_score} = w_{\text{acc}} \times \Delta \text{replay_acc} + w_{\text{margin}} \times \Delta \text{replay_margin} + w_{\text{proto}} \times \Delta \text{replay_proto_cos}$$

項目	評価しているもの
$\Delta \text{replay_acc}$	予測ラベルとの一致率の変化
$\Delta \text{replay_margin}$	1位予測と2位予測の余裕の変化
$\Delta \text{replay_proto_cos}$	特徴ベクトルと特徴中心の整合度の変化
$w_{\text{acc}}, w_{\text{margin}}, w_{\text{proto}}$	各評価項目をどれだけ重視するかを決める重み


正解ラベルがないため、過去の高信頼入力に対する悪化を手がかりに採用可否を決める。

更新候補ごとに、TCFormer 内で変更する場所が異なる

3/6 提案

更新候補は、BN統計・特徴中心・出力偏りなど、TCFormer 内の異なる場所に作用する。

TCFormer operator 適応マップ



更新候補は、変更箇所だけでなく失敗時のリスクも異なる

3/6 提案

更新候補は、TCFormer 内の異なる場所に作用する。
そのため、改善できる対象だけでなく、誤更新時に壊しやすい部分も異なる。

更新候補	変更箇所	変えるもの	主なリスク
prototype_update	特徴空間	特徴中心	特徴中心の汚染
logit_bias_update	出力空間	出力の偏り	クラス偏り
deep_BN_update	深層BN	平均・分散	特徴表現の不安定化
hybrid_BN_update	浅層mean + 深層BN	浅層平均, 深層平均・分散	柔軟性が低い
shallow_var_update	浅層BN	浅層分散	悪化リスクが高い
no_update	なし	なし	改善機会を逃す

4. 実験結果


BCIC IV-2a の9被験者で, source_only を基準に比較した

項目	設定
dataset	BCIC IV-2a
setting	cross-session
subjects	9被験者
baseline	source_only (適応なし)
comparison	source_only vs replay_safe 系
augmentation	あり
metrics	平均精度 / 改善幅 / 最悪悪化幅 / HSC

HSC : 0.5pp以上悪化した被験者数


OTTA の効果は, 適応しない source_only からどれだけ改善したかで評価する。

Replay-SafeCommit は平均精度を改善し、0.5pp以上の悪化を出さなかった




source_only に対する平均改善と、被験者単位の悪化抑制を同時に確認した。

replay_safe_uniform は、0.5pp以上悪化した被験者を出していない



平均改善を示しつつ、被験者単位の大きな悪化を抑えられている。

replay は危険な候補を棄却し，有効な候補だけを採用する



単に更新を止めるのではなく，候補ごとの影響を比較して採用可否を決める。

安全な選択器は見たが、補正器そのものはまだ弱い

今回確認できたこと

- ・ source_only に対して +0.69pp 改善
- ・ HSC=0/9 で、0.5pp以上の悪化なし
- ・ 複数の更新候補から安全に選ぶ仕組みとして有望

残る課題

補正力：平均精度の押し上げはまだ限定的

再現性：5 seed・複数データセットで確認が必要

比較条件：hybrid@0.01 との同一条件比較が未完了

実装条件：online 低遅延での成立は未確認



次の論点

Replay-SafeCommit を **安全な選択器** として残しつつ、**より強い補正器** を更新候補として追加する。

次は、Replay-SafeCommit を安全な選択器として残し、補正器そのものを強化する。

5. 論文調査

BT TA-DG は、重みを更新せずに予測を補正する EEG-MI TTA 手法である

論文の問題設定

- EEG-MI は被験者差・session差により特徴分布がずれる
- 勾配更新型TTAは、計算コストと誤更新のリスクがある
- 浅い統計整列だけでは、時系列的な予測分布のずれを捉えにくい

中核アイデア

1. Dirichlet feature projection
時系列予測を低次元パラメータ α に圧縮



2. GMM-driven inference
過去入力の α 分布をGMMで保持



3. Bayesian calibration
補正前予測とGMM尤度を統合し、
予測を補正

この論文の読みどころ

- モデル重みは更新しない
- 過去のtarget入力分布を使って現在入力を補正する
- 平均精度とリアルタイム性を両立している

本研究での読み替え
BT TA-DG は Replay-SafeCommit に追加する
「強い補正器候補」とみなせる。

出典：Luo et al., "Bayesian Test-Time Adaptation via Dirichlet Feature Projection and GMM-Driven Inference for Motor Imagery EEG Decoding," ICLR 2026.

BT TA-DG の本質は、重み更新ではなく、予測分布の Bayesian 補正で target 側へ適応する点にある。

BT TA-DG は平均精度を大きく改善するが、悪化抑制は主眼ではない

Table 8 の要点 (Source Only vs Full Model)

設定	source_only	BT TA-DG	Δ
BNCI2014001 cross-session	80.62	86.50	+5.88pp
BNCI2014001 cross-subject	75.30	78.70	+3.40pp
BNCI2014002 cross-subject	76.40	80.29	+3.89pp
BNCI2015001 cross-subject	73.92	77.92	+4.00pp
SHU MI cross-subject	61.02	64.06	+3.04pp

論文全体では、Dirichlet と GMM を両方入れた Full Model が最良。

実装面の示唆

- 実装面の示唆
 - ・ 15.7 ms / 入力
 - ・ 勾配更新なし
 - ・ リアルタイム性を意識
- 本研究での注意
 - ・ 平均精度の押し上げは強い
 - ・ ただし、被験者単位の悪化抑制は主眼ではない

安全な採用判断は Replay-SafeCommit 側で担う

出典：Luo et al., "Bayesian Test-Time Adaptation via Dirichlet Feature Projection and GMM-Driven Inference for Motor Imagery EEG Decoding," ICLR 2026.

BT TA-DG は「平均精度を強く押し上げる補正器」として有望であり、本研究ではその安全な採用法が論点になる。

BT TA-DG は、Replay-SafeCommit に追加する更新候補として扱う


取り入れたい点

- 勾配更新なしで、平均精度を大きく改善している
- 予測列の揺れを Dirichlet パラメータ α として扱える
- GMM により、過去 target 入力の分布情報を使える
- 「重み更新」ではなく「出力補正」として候補化しやすい

そのままは使いにくい点

- SincAdaptNet 前提であり、TCFormer への接続設計が必要
- 主眼は平均精度向上であり、悪化抑制は本研究側で見る必要がある
- 過去入力分布の利用には、誤ラベル由来の汚染リスクが残る
- 主評価は cross-subject 中心で、本研究の主設定は cross-session

統合イメージ



BT TA-DG を「競合手法」ではなく「追加候補 operator」として扱うのがポイント

出典：Luo et al., "Bayesian Test-Time Adaptation via Dirichlet Feature Projection and GMM-Driven Inference for Motor Imagery EEG Decoding," ICLR 2026.

次の一手は、BT TA-DG を candidate operator として追加し、replay 判定下で効果と悪化リスクを比較することである。

6. 今後の方針

Replay-SafeCommit の次の課題は、候補の強化と選択精度の向上である

Replay-SafeCommit の性能 = 更新候補の質 × 選択方法の質

1. 更新候補の強化

目的：平均精度を押し上げる候補を増やす

- 既存候補だけでは改善幅が +0.69ppにとどまる
- prototype /logit biasだけでは、クラス内分散や不確実性を扱いにくい
- Bayesian calibrationを新しい更新候補として追加する
- 補正器単体の効果を確認してから、既存候補群に統合する

2. 選択方法の強化


目的：良い候補だけを採用し、危険候補を棄却する

- sim_score の重み・閾値が固定で、被験者状態に追従しにくい
- replay buffer が偏ると、採用判断も偏る
- 高信頼な誤分類が入ると、安全性評価が汚染される
- 重み調整・buffer 多様性・閾値設計を検証する

候補を強くするだけでは危険。強い候補を安全に選べる仕組みまで改善する。

今後は、強い補正器を追加しつつ、Replay-SafeCommit の採用判断そのものも改善する。

候補強化：Bayesian calibration を新しい更新候補として追加する



まず補正器単体の効き方を確認し、その後 Replay-SafeCommit に統合する。

選択方法の強化：sim_score と replay buffer の信頼性を高める

現状の選択方法	残る課題	改善案
■ 候補更新を仮適用する ■ replay buffer 上で sim_score を計算する ■ $\text{sim_score} > 0$ なら採用, ≤ 0 なら巻き戻し	■ $w_{\text{acc}} / w_{\text{margin}} / w_{\text{proto}}$ の重みが固定 ■ buffer が特定クラスや古い入力に偏る可能性がある ■ 高信頼な誤分類が buffer に入ると, 評価自体が汚染される ■ 高信頼な誤分類が buffer に入ると, 評価自体が汚染される ■ 強い候補を追加すると, 誤採用時の悪化リスクも大きくなる	■ sim_score 重みの ablation / 最適化 ■ buffer のクラスバランス・多様性制御 ■ 新旧入力の重み付けを分ける ■ 被験者状態に応じた採用閾値の調整commit / rollback 条件の ablation



選択方法の改善は, 強い補正器を追加したときの誤採用リスクを抑えるために必要である。


強い候補を追加するほど, その候補を安全に採用できるかが Replay-SafeCommit の中核課題になる。

参考文献

1. Altaheri, H., Karray, F., & Karimi, A.-H. (2025). Temporal convolutional transformer for EEG based motor imagery decoding. Scientific Reports, 15(1), 32959. <https://doi.org/10.1038/s41598-025-16219-7>
2. Luo, H., Lu, N., Wang, X., & Niu, X. (2026). Bayesian Test-Time Adaptation via Dirichlet Feature Projection and GMM-Driven Inference for Motor Imagery EEG Decoding. ICLR 2026.

Appendix


安全制約を満たした上で mean Δ が高い手法を採択する



本研究では、平均精度だけでなく worst-case harm を制約として扱う。

S7では replay 系が複数 seed で一貫して改善している

Appendix



S7 では replay 系が複数 seed で改善し、variance reduction の可能性を示している。

Dirichlet 分布は，予測の偏りと確信度を α で表す

Figure 1 : Dirichlet 分布の直感




図. Dirichlet分布[2]

読み取り方

- $\alpha_0 = \sum \alpha_i$ が大きいほど，予測のばらつきが小さい
- ある α_i が大きいほど，そのクラス方向へ分布が寄る
- α は「どのクラス寄りか」と「どれだけ確信しているか」を同時に表す

本研究での見方

時間方向の予測列を，単なる平均ではなく「分布の形」として扱える。



Replay-SafeCommit では，この α を候補補正の影響を測る評価用表現として使える可能性がある。

Figure 1 : 各三角形は確率 simplex，上の点群は Dirichlet からのサンプル

出典 : Luo et al., "Bayesian Test-Time Adaptation via Dirichlet Feature Projection and GMM-Driven Inference for Motor Imagery EEG Decoding," ICLR 2026.

Dirichlet 射影は，時間方向の予測の揺れを，解釈しやすい低次元表現 α に圧縮する役割を持つ。

BT TA-DG は、過去の target 分布と現在の予測を統合して補正する



勾配更新しないため、「重みを壊さない補正器」として使いやすい。

出典：Luo et al., "Bayesian Test-Time Adaptation via Dirichlet Feature Projection and GMM-Driven Inference for Motor Imagery EEG Decoding," ICLR 2026.

BT TA-DG は、重みを変えずに「過去の target 分布」と「現在の補正前予測」を統合して出力を補正する。